



**DATASALUD PERÚ: SISTEMA INTEGRADO DE  
BASE DE DATOS PARA LA GESTIÓN DEL  
MINSAL.**

**Curso:** Base de Datos Avanzadas y Big Data (CIIN1021P).

**INTEGRANTES:**

- Anthony Jeremy Marín Anticona
- Juan Diego Geronimo Temoche
- Cesar Manuel Antonio Viteri Vitteri
- Isamad Daniel Guzman Suarez
- Carlos Cristhian Mar Diaz Zamora



06 / 10 / 2026

# ÍNDICE

|                                                                                 |           |
|---------------------------------------------------------------------------------|-----------|
| <b>ÍNDICE.....</b>                                                              | <b>2</b>  |
| <b>INTRODUCCIÓN.....</b>                                                        | <b>4</b>  |
| <b>1. Definición del reto, alcance y supuestos.....</b>                         | <b>4</b>  |
| 1.1 Contexto, pregunta de gestión y criterios de éxito.....                     | 4         |
| 1.2 Requerimientos funcionales y criterios de éxito.....                        | 5         |
| 1.3 Ficha de los Datasets.....                                                  | 6         |
| 1.4 Calidad de datos.....                                                       | 6         |
| 1.5 Supuestos declarados y decisiones de diseño.....                            | 7         |
| 1.6 Articulación curricular.....                                                | 7         |
| 1.7 Planificación y ruta del proyecto (Cronograma).....                         | 8         |
| 1.8 Dependencias explícitas (ruta crítica).....                                 | 9         |
| 1.9 Matriz de trazabilidad de requerimientos.....                               | 9         |
| <b>2. Automatización mediante objetos de base de datos.....</b>                 | <b>9</b>  |
| 2.1 Justificación de diseño y comparación de alternativas.....                  | 9         |
| 2.2 Implementación de objetos T-SQL.....                                        | 11        |
| 2.3 Evidencia de ejecución y manejo de errores (prueba técnica).....            | 12        |
| 2.4 Evidencia log (AuditoriaLog).....                                           | 12        |
| <b>3. Seguridad, rendimiento y cumplimiento normativo (Ley N.º 29733).....</b>  | <b>13</b> |
| 3.1 Gestión de roles y segregación de privilegios.....                          | 13        |
| 3.2 Políticas de respaldo y recuperación.....                                   | 13        |
| 3.3 Optimización y planes de ejecución.....                                     | 13        |
| 3.4 Lista de verificación (Ley N.º 29733) y análisis de consecuencias.....      | 14        |
| <b>4. Integración SQL-NoSQL y decisión arquitectónica.....</b>                  | <b>14</b> |
| 4.1 Exploración y operaciones NoSQL (MongoDB).....                              | 14        |
| 4.2 Análisis comparativo técnico (SQL vs. NoSQL).....                           | 15        |
| 4.3 Decisión arquitectónica final.....                                          | 16        |
| <b>5. Data Warehouse y procesos ETL.....</b>                                    | <b>16</b> |
| 5.1 Diseño del modelo dimensional.....                                          | 16        |
| 5.2 Justificación metodológica: Kimball vs. Inmon.....                          | 17        |
| 5.3 Proceso ETL funcional (Extracción, Transformación y Carga).....             | 17        |
| <b>6. Dashboard BI, KPIs y análisis OLAP.....</b>                               | <b>18</b> |
| 6.1 Gobernanza de datos y metadatos de los KPIs.....                            | 18        |
| 6.2 Operación OLAP demostrable (Drill-Down).....                                | 19        |
| 6.3 Narrativa visual y respuestas a preguntas de negocio.....                   | 19        |
| <b>7. Análisis Big Data con Apache Spark y evaluación de escalabilidad.....</b> | <b>20</b> |
| 7.1 Entorno de ejecución y objetos Spark.....                                   | 20        |
| 7.2 Operación analítica masiva y benchmarking.....                              | 20        |
| 7.3 Análisis de eficiencia y escalabilidad.....                                 | 21        |
| <b>8. Reflexión ética y responsabilidad profesional.....</b>                    | <b>21</b> |
| 8.1 Dilemas éticos identificados y decisiones justificadas.....                 | 21        |
| 8.2 Consecuencias sobre los afectados.....                                      | 22        |
| 8.3 Análisis de escalabilidad (impacto a nivel nacional).....                   | 22        |

|                                                                                             |           |
|---------------------------------------------------------------------------------------------|-----------|
| 8.4 Matriz de trazabilidad.....                                                             | 23        |
| <b>9. Conclusiones, limitaciones y recomendaciones.....</b>                                 | <b>23</b> |
| <b>10. Referencias bibliográficas.....</b>                                                  | <b>24</b> |
| <b>11. Anexos.....</b>                                                                      | <b>25</b> |
| - Anexo A: Script SQL de la función fn_NormalizarTexto.....                                 | 25        |
| - Anexo B: Script SQL de los procedimientos almacenados (ingesta).....                      | 26        |
| - Anexo C: Script SQL de los procedimientos almacenados (limpieza de duplicados)...         | 26        |
| - Anexo D: Script SQL Trigger trg_ValidaIntegridadZoonosis.....                             | 27        |
| - Anexo E: Script SQL Trigger tr_AuditoriaZoonosis.....                                     | 28        |
| - Anexo F: Prueba Técnica (1era Ingesta).....                                               | 28        |
| - Anexo G: Prueba Técnica (2da Ingesta).....                                                | 29        |
| - Anexo H: Comprobación de las ingestas.....                                                | 29        |
| - Anexo I: Asignación de roles.....                                                         | 29        |
| - Anexo J: Backups del proyecto (prueba).....                                               | 30        |
| - Anexo K: Comparación del plan de ejecución antes y después del índice.....                | 30        |
| - Anexo L: Creación de colección atenciones_zoonosis.....                                   | 31        |
| - Anexo M: Scripts DDL con la creación de las tablas Dim_Tiempo, Dim_Ubicacion, etc..<br>31 |           |
| - Anexo N: Captura visual del diagrama del modelo relacional/estrella.....                  | 32        |
| - Anexo Ñ: Script del proceso de ETL para los datasets.....                                 | 33        |
| - Anexo O: Esquema de Power BI, relaciones y conexiones.....                                | 35        |
| - Anexo P: Dashboard de Power BI, visualización de los 3 KPIs.....                          | 35        |
| - Anexo Q: Evidencia para el punto 1 - DataFrames.....                                      | 36        |
| - Anexo R: Script de SparkSQL (prueba de tiempo).....                                       | 36        |
| - Anexo S: Script de prueba de tiempo en SSMS.....                                          | 37        |
| - Anexo T: Declaración institucional de uso de IA.....                                      | 38        |

## INTRODUCCIÓN

La Dirección Regional de Salud (DIRESA) de La Libertad enfrenta un desafío crítico en la gestión de enfermedades zoonóticas: la recepción de datos desde múltiples establecimientos genera reportes con inconsistencias temporales, duplicados y vacíos de información geográfica. Además, el manejo histórico de estos expedientes carece de mecanismos formales de auditoría, exponiendo a la institución a graves incumplimientos legales frente a la Ley de Protección de Datos Personales (Ley N.º 29733).

El proyecto "DataSalud Perú" propone solucionar esta crisis mediante un sistema integrado y automatizado. Utilizando bases de datos abiertas del MINSA y el INEI, el proyecto implementa una arquitectura transaccional en SQL Server que delega las reglas de limpieza y validación directamente al motor de la base de datos (in-database). Mediante Procedimientos Almacenados y Triggers, se garantiza que la ingesta de registros históricos bloquee de inmediato las anomalías y sea inmune a alteraciones externas.

Asimismo, el proyecto incorpora un estricto modelo de seguridad basado en roles y un log inmutable de operaciones (trazabilidad transaccional) para salvaguardar la privacidad y auditar el 100% de las modificaciones, cumpliendo a cabalidad con la normativa vigente.

Finalmente, esta arquitectura sienta las bases para un futuro Data Warehouse bajo la metodología de Ralph Kimball. Al garantizar un flujo de datos limpio y estructurado, el proyecto habilitará la creación de tableros de control (Dashboards) que permitirán a los directivos de la DIRESA optimizar la asignación de recursos y responder con agilidad ante posibles brotes epidemiológicos en la región.

## 1. Definición del reto, alcance y supuestos

### 1.1 Contexto, pregunta de gestión y criterios de éxito

#### Contexto

La Dirección Regional de Salud (DIRESA) de La Libertad enfrenta un desafío crítico en la gestión de enfermedades zoonóticas de notificación obligatoria (Leptospirosis, Peste, Rabia Urbana, entre otras).

La recepción de reportes desde las IPRESS presenta inconsistencias estructurales, duplicados y vacíos geográficos que impiden una correcta focalización de los recursos sanitarios.

#### Pregunta de Gestión

*¿Cuál es la carga de morbilidad y la distribución espacio-temporal de las enfermedades zoonóticas en la región La Libertad, y cómo se relaciona esta carga con la capacidad de los establecimientos de salud (IPRESS) para optimizar la asignación de recursos ante brotes epidemiológicos?*

## 1.2 Requerimientos Funcionales y Criterios de Éxito

Para dar respuesta a la pregunta de gestión y asegurar la viabilidad del sistema, se definieron tres requerimientos funcionales con criterios de éxito verificables:

- **Requerimiento Funcional 1:** Auditoría Transaccional Obligatoria (Trazabilidad).
  - **Descripción:** El sistema debe registrar automáticamente todo evento de inserción, actualización o borrado sobre la tabla de hechos de zoonosis, capturando el usuario, la estampa de tiempo exacta y el tipo de operación para cumplir con la auditoría legal.
  - **Criterio de éxito:** Al forzar un **INSERT** o **UPDATE** manual desde la cuenta de un usuario 'AnalistaDatos', la tabla **AuditoriaLog** debe reflejar inmediatamente la operación.
  
- **Requerimiento Funcional 2:** Validación de Integridad Temporal (Bloqueo de Inconsistencias).
  - **Descripción:** El motor de base de datos debe impedir la persistencia de casos clínicos cuya fecha de notificación médica sea futura o cuyo año epidemiológico no coincida con el año calendario reportado.
  - **Criterio de éxito:** La ejecución de un script de carga que contenga registros con Año = 2035 debe desencadenar un error tipo **ROLLBACK**, deteniendo la transacción e impidiendo la contaminación de la tabla.
  
- **Requerimiento Funcional 3:** Consolidación Geográfica de Ubigeo.
  - **Descripción:** El sistema debe imputar automáticamente el distrito de jurisdicción principal cuando un registro ingrese con el campo 'Localidad' nulo o vacío, apoyándose en la tabla maestra de **UBIGEO** del **INEI**.
  - **Criterio de éxito:** Tras procesar un lote crudo con 50 registros sin localidad, una consulta analítica debe verificar que el 100% de esos registros posean un distrito asignado válido.

### 1.3 Ficha de los Datasets

**Dominio Epidemiológico:** Sistema de vigilancia epidemiológica de enfermedades zoonóticas de notificación obligatoria (Leptospirosis, Peste, Rabia Urbana, Tifus, entre otras) para la Dirección Regional de Salud (DIRESA) La Libertad, orientado a optimizar la contención de brotes, focalización de recursos sanitarios y auditoría de datos clínicos de la población liberteña.

| DATASET                                                                                                         | FUENTE                                                                                                                                                                                                                                                                                                                     | FECHA DE DESCARGA        | JUSTIFICACIÓN                                                                                                                                                                                 |
|-----------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Dataset Principal (Hechos):</b><br>Vigilancia Epidemiológica de Zoonosis (2000 - 2024).                      | Plataforma Nacional de Datos Abiertos del Perú<br>( <a href="https://www.datosabiertos.gob.pe/dataset/vigilancia-epidemiologica-de-las-zoonosis">https://www.datosabiertos.gob.pe/dataset/vigilancia-epidemiologica-de-las-zoonosis</a> )                                                                                  | 14 de septiembre         | Centraliza el histórico oficial del Centro Nacional de Epidemiología, Prevención y Control de Enfermedades (CDC-MINSA), permitiendo modelar series temporales a nivel distrital y provincial. |
| <b>Dataset Secundario (Dimensión):</b><br>Catálogo de Establecimientos de Salud (RENAES) y Codificación UBIGEO. | Registro Nacional de IPRESS<br><a href="https://app20.susalud.gob.pe:8086/registro-renipress-webapp/listadoEstablecimientosRegistrados.htm?action=mostrarBuscar#no-back-button">https://app20.susalud.gob.pe:8086/registro-renipress-webapp/listadoEstablecimientosRegistrados.htm?action=mostrarBuscar#no-back-button</a> | 14 de septiembre de 2026 | Provee la base de estandarización geográfica territorial para vincular los códigos UBIGEO y clasificar jerárquicamente las microredes de salud en la región.                                  |

### 1.4 Calidad de datos

Se aplicó un análisis exploratorio preliminar sobre los **128,084 registros brutos** del dataset de Zoonosis, identificando las siguientes incidencias críticas que impactan directamente en el diseño del pipeline ETL:

- **Duplicidad Exacta: 2,388 filas (1.86% del total).**  
**Impacto:** Provocan una sobredimensión artificial de tasas de incidencia y sesgo en las alertas tempranas.
- **Localidad (Nulos/Vacíos): 1,412 registros (1.10%).**  
**Impacto:** Representan pérdida de resolución geográfica granular a nivel de centro poblado.
- **Diagnóstico Incompleto: 185 registros (0.14%).**  
**Impacto:** Generan ambigüedad al impedir segregar casos confirmados de sospechosos.
- **Edad (Formatos anómalos): 92 registros (0.07%).**  
**Impacto:** Dificultan la segmentación de grupos etarios de riesgo poblacional.

## 1.5 Supuestos Declarados y Decisiones de Diseño

Frente a las anomalías detectadas, el equipo de ingeniería adoptó los siguientes supuestos para el tratamiento de datos, garantizando la viabilidad del proyecto:

- **Supuesto de Duplicidad:** Se asume que los 2,388 registros idénticos corresponden a retransmisiones por errores de red en la ingesta hospitalaria descentralizada. Decisión de diseño: Se aplicó una regla de deduplicación determinística en la etapa de extracción (ETL) para no falsear los KPIs de morbilidad.
- **Supuesto de Imputación Territorial:** Ante la ausencia de la variable "Localidad", se asume la imputación mediante el valor del distrito cabecera. Decisión de diseño: Esto garantiza preservar el cruce con la dimensión UBIGEO en el modelo Kimball sin perder el registro clínico completo.
- **Supuesto de Diagnóstico:** Los registros sin estado de validación médica fueron tipificados estrictamente como 'NO ESPECIFICADO'. Decisión de diseño: Esto evita catalogar falsos positivos y mantiene la integridad semántica del futuro análisis OLAP.

## 1.6 Articulación Curricular

El presente proyecto integrador articula progresivamente las competencias de la línea de ingeniería de datos:

- **Saberes previos (Base de Datos - Ciclo 3):** Se aplicaron los fundamentos de normalización relacional, restricciones de integridad (PK, FK) y encapsulamiento de reglas de negocio en el motor mediante procedimientos almacenados y triggers transaccionales.
- **Proyección a Ciencia de Datos:** Las rutinas de limpieza (data wrangling), la imputación de nulos y la estructuración dimensional preparan el terreno para el futuro entrenamiento de modelos de Machine Learning para predicción de brotes epidemiológicos.
- **Proyección a Ingeniería de Software:** Se implementó una arquitectura desacoplada, asegurando que la capa de persistencia (SQL Server) opere de forma inmutable e independiente de la aplicación (Python/BI), promoviendo la segregación de roles y la auditoría exigida por normativas legales.

### 1.7 Planificación y ruta del proyecto (Cronograma)

Para garantizar la entrega integral del sistema "DataSalud Perú" en la Evaluación Final, se diseñó un cronograma de choque estructurado en 6 hitos clave, alineado con las semanas de cierre del ciclo académico.

| Hito Fechado | Bloque Temático                                                                                                                                                                                                                                                                                                       | Responsable    | Herramientas             |
|--------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------|--------------------------|
| 1 Sept 2026  | <b>Hito 1: Ingesta In-Database (Finalizada).</b><br>Despliegue de los SPs y Triggers de auditoría y validación temporal en SQL Server.                                                                                                                                                                                | Cesar Viteri   | SSMS (T-SQL)             |
| 11 Sept 2026 | <b>Hito 2: Seguridad y Roles (Finalizada).</b><br>Implementación de roles según Ley N.º 29733 y optimización con índices (Execution Plans).                                                                                                                                                                           | Anthony Marín  | SSMS (T-SQL)             |
| 20 Sep 2026  | <b>Hito 3: Exploración NoSQL.</b><br>Diseño y carga de expedientes semiestructurados en MongoDB para contrastar la persistencia frente a SQL Server.                                                                                                                                                                  | Isamad Guzman  | MongoDB, Python          |
| 30 Sep 2026  | <b>Hito 4: Data Warehouse y ETL (Kimball).</b><br>Diseño del esquema estrella, programación del pipeline ETL para poblar Fact_Casos_Zoonosis cruzado con el catálogo RENAES.                                                                                                                                          | Juan Diego     | Python, SSIS             |
| 03 Oct 2026  | <b>Hito 5: Inteligencia de Negocios (BI).</b><br>Construcción de las fórmulas DAX y despliegue del Dashboard con KPIs de morbilidad y operaciones OLAP.                                                                                                                                                               | Anthony Marín  | Power BI                 |
| 06 Oct 2026  | <b>Hito 6: Benchmarking Big Data.</b><br>Ejecución del pipeline analítico con DataFrames para evaluar tiempos de procesamiento masivo vs. SQL Server.                                                                                                                                                                 | Carlos Díaz    | PySpark (Colab)          |
| 06 Oct 2026  | <b>Hito 7: Decisiones Finales.</b><br>A partir de todo el análisis realizado en el transcurso del proyecto se concluye y decide la arquitectura tecnológica definitiva (SQL Server local vs. ecosistema Big Data en la nube) para la DIRESA, y se consolida la presentación del informe final, anexos y repositorios. | Grupo Completo | Word, PowerPoint, GitHub |

## 1.8 Dependencias Explícitas (Ruta Crítica)

El profesor señaló en la etapa previa la necesidad de declarar una ruta crítica estricta. En este proyecto, la ruta crítica de extremo a extremo (Datos de origen → Almacenamiento → Transformación → Análisis) está dada por la dependencia ineludible de los hitos 4, 5 y 6:

1. **Dependencia Técnica 1:** El proceso de Inteligencia de Negocios (Hito 5) está bloqueado por el Hito 4. No se pueden programar las métricas DAX en Power BI sin que el modelo dimensional (Esquema Estrella) haya sido poblado exitosamente por el proceso ETL.
2. **Dependencia Técnica 2:** La ejecución de PySpark (Hito 6) requiere que la curaduría de anomalías iniciales haya finalizado, garantizando que el dataset a procesar en Colab sea idéntico en integridad al alojado en SQL Server, permitiendo así una comparación (benchmarking) válida de tiempos de CPU.
3. **Dependencia Técnica 3:** El testeo del Hito 2 (Seguridad) dependió de que el Hito 1 (Triggers) no entrara en conflicto (Deadlocks) con las políticas de concurrencia de los nuevos roles aplicados.

## 1.9 Matriz de Trazabilidad de Requerimientos

| Código RF | Requerimiento Funcional             | Componente / Objeto Técnico                              | Criterio de Verificación                                                   |
|-----------|-------------------------------------|----------------------------------------------------------|----------------------------------------------------------------------------|
| RF-01     | Auditoría Transaccional Obligatoria | Trigger<br>trg_AuditoriaZoonosis &<br>Tabla AuditoriaLog | Registro automático del evento en AuditoriaLog con usuario y timestamp.    |
| RF-02     | Validación de Integridad Temporal   | Trigger<br>trg_ValidaIntegridadZoonosis                  | Ejecución de ROLLBACK ante inserción con fecha/año futuro o edad negativa. |
| RF-03     | Consolidación Geográfica de Ubigeo  | Pipeline ETL<br>(Python/Pandas) &<br>Dim_Ubicacion       | 100% de registros procesados vinculados a un código UBIGEO válido.         |

## 2. Automatización mediante objetos de base de datos

### 2.1 Justificación de Diseño y Comparación de Alternativas

Para la fase de ingesta, validación de integridad temporal y auditoría, se requería una arquitectura que garantizara el cumplimiento de la Ley N.º 29733 sin degradar el rendimiento. Se evaluó implementar estas reglas de negocio en tres posibles capas:

(1) Lógica en Base de Datos vía T-SQL (enfoque elegido). // (2) Capa de Aplicación vía Python/API.  
// (3) Herramienta de Integración ETL dedicada como SSIS.

Se seleccionó la Automatización in-database (Opción 1) descartando las alternativas 2 y 3 basándose en los siguientes criterios técnicos estructurados:

| Criterio Técnico                               | (Elegida)<br>Automatización en Base de Datos (T-SQL, Triggers, SPs)                                                                                               | (Descartada 1)<br>Validación en Capa de Aplicación (Python/API Backend)                                                                                         | (Descartada 2)<br>Automatización vía Herramienta ETL Dedicada (SSIS / Apache Airflow)                                                                                |
|------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Vulnerabilidad de los Puntos de Ingesta</b> | <b>Centralizada e invulnerable:</b> Toda transacción pasa obligatoriamente por los objetos del motor, independientemente de qué herramienta o usuario se conecte. | <b>Vulnerable:</b> Si un analista se conecta por consola SQL o si se integra otro sistema futuro, las reglas de la API se omiten ( <i>Bypass</i> de seguridad). | <b>Media:</b> Protege la ingesta masiva ( <i>batch</i> ), pero no audita ni bloquea inserciones manuales o micro-transaccionales (OLTP).                             |
| <b>Sobrecarga de Red (Latencia)</b>            | <b>Mínima:</b> La base de datos resuelve, bloquea (Rollback) y audita en el propio servidor ( <i>in-memory</i> ) sin tráfico de retorno a través de la red.       | <b>Alta:</b> Requiere constante tráfico de ida y vuelta ( <i>round-trips</i> ) para validar las restricciones registro por registro a través de la red.         | <b>Baja (en batch):</b> Muy eficiente para grandes cargas masivas, pero ineficiente para el control y auditoría de eventos individuales en tiempo real.              |
| <b>Consistencia Transaccional (ACID)</b>       | <b>Fuerte:</b> Garantizada nativamente por el aislamiento transaccional del gestor relacional (SQL Server). Evita lecturas sucias.                                | <b>Débil/Compleja:</b> Mayor riesgo de bloqueos fantasma o inconsistencias entre hilos de aplicación si no se gestionan bien los ORMs.                          | <b>Fuerte (a nivel lote):</b> Garantiza la integridad del lote completo, pero carece del control fino de concurrencia de un RDBMS para abortar eventos individuales. |

**Condición de Preferencia para Alternativa Descartada:** La Alternativa Descartada 2 (Herramienta ETL SSIS) habría sido preferible únicamente si el requerimiento principal fuese migrar y limpiar históricamente todo el ecosistema de la DIRESA (crear un Data Warehouse inmenso en modo batch) sin la necesidad estricta de auditoría transaccional en tiempo real. SSIS maneja mejor los flujos de transformación visuales de millones de registros que los Procedimientos Almacenados. Sin embargo, dado que el reto prioriza la auditoría inmutable de modificaciones y el bloqueo de inconsistencias al momento exacto del evento para cumplir con la Ley N.º 29733, el control in-database (T-SQL) resulta indispensable.

## 2.2 Implementación de Objetos T-SQL

Para cumplir con los requerimientos funcionales del sistema y aislar la lógica de negocio, se codificaron los siguientes objetos en la base de datos DataSalud\_DB:

- **Función Escalar (fn\_NormalizarTexto):** Se creó una función reusable que recibe parámetros de texto (como localidad o diagnóstico) y devuelve la cadena estandarizada utilizando las operaciones integradas UPPER y TRIM. Esto asegura que la base de datos elimine espacios en blanco redundantes y mantenga un formato mayúsculo homogéneo antes de la carga al Data Warehouse.

[Anexo A: Script SQL de la Función fn\\_NormalizarTexto](#)

- **Procedimientos Almacenados con Control Transaccional:**

1. **sp\_IngestarLoteZoonosis:** Es el procedimiento principal de carga. Incorpora un manejo estricto de transacciones mediante bloques **BEGIN TRY, COMMIT** para consolidar inserciones válidas, y **BEGIN CATCH con ROLLBACK** para revertir la operación completa en caso de fallo, evitando la persistencia de datos corruptos.
2. **sp\_LimpiarDuplicadosZoonosis:** Procedimiento analítico diseñado para ejecutar operaciones de deduplicación, identificando y eliminando registros históricamente retransmitidos idénticos para mantener la consistencia de los posteriores conteos OLAP.

[Anexo B: Script SQL de los Procedimientos Almacenados](#)

[Anexo C: Script SQL de los Procedimientos Almacenados \(Limpieza Duplicados\)...](#)

- **Triggers de Integridad y Auditoría:**

1. **trg\_ValidaIntegridadZoonosis (INSTEAD OF INSERT):** Actúa como barrera primaria. Intercepta los registros dirigidos a la tabla **Staging\_Zoonosis** y verifica que no existan fechas o años epidemiológicos futuros (mayores a **GETDATE()**) ni edades negativas. Si detecta anomalías, lanza una excepción mediante **RAISERROR** y ejecuta un **ROLLBACK TRANSACTION**.

[Anexo D: Script SQL Trigger trg\\_ValidaIntegridadZoonosis](#)

2. **trg\_AuditoriaZoonosis (AFTER INSERT, UPDATE):** Cumple el rol de trazabilidad legal. Captura información del sistema (estampa de tiempo exacta y el usuario de red) insertando de forma inmutable la evidencia de éxito o fallo en la tabla **AuditoriaLog**.

[Anexo E: Script SQL Trigger tr\\_AuditoriaZoonosis](#)

### 2.3 Evidencia de Ejecución y Manejo de Errores (Prueba Técnica)

Para verificar la solidez de la arquitectura in-database ante excepciones, se ejecutó una prueba simulando la inyección de datos anómalos.

- **Hipótesis:** Se espera comprobar que el control centralizado mediante objetos T-SQL es capaz de bloquear el 100% de inserciones con datos anómalos o futuros (Año > 2026) y auditar de forma inmutable cada intento fallido y exitoso, mitigando el riesgo de contaminación de los catálogos oficiales.
- **Prueba ejecutable:** Se simuló un escenario inyectando un lote de datos mediante el procedimiento sp\_IngestarLoteZoonosis donde se incluyó deliberadamente un registro con año epidemiológico '2035', ejecutado por el usuario JUAN-GB \ Juan-GB.
- **Resultado (Evidencia):** La transacción anómala fue interceptada y revertida (Rollback) por el motor SQL. El sistema de log registró simultáneamente la operación exitosa de los datos válidos y la denegación del dato anómalo.

### 2.4 Evidencia Log (AuditoriaLog)

| Log ID | Tabla Origen     | Operación            | Usuario             | Timestamp                  | Mensaje de Estado                                                                                   |
|--------|------------------|----------------------|---------------------|----------------------------|-----------------------------------------------------------------------------------------------------|
| 2      | Staging_Zoonosis | ERROR_ING<br>ESTA    | ANTHONY\<br>Anthony | 2026-10-06<br>13:01:37.537 | Error de<br>Integridad: Se<br>intentó insertar un<br>registro con año<br>futuro o edad<br>negativa. |
| 3      | Staging_Zoonosis | INSERCIÓN<br>EXITOSA | ANTHONY\<br>Anthony | 2026-10-06<br>13:02:20.467 | Operación<br>ejecutada con éxito<br>sobre la tabla.                                                 |

[Anexo F: Prueba Técnica \(1era Ingesta\).](#)

[Anexo G: Prueba Técnica \(2da Ingesta\).](#)

[Anexo H: Comprobación de las Ingestas.](#)

### 3. Seguridad, rendimiento y cumplimiento normativo (Ley N.º 29733)

#### 3.1 Gestión de Roles y Segregación de Privilegios

Para dar cumplimiento estricto a las disposiciones de seguridad de la Ley de Protección de Datos Personales (Ley N.º 29733) y alinearse con los controles ISO 27001, se implementó un modelo de control de acceso basado en roles (RBAC) en el servidor de base de datos. Se crearon tres roles con privilegios granulados y mutuamente excluyentes:

1. **Rol\_Administrador:** Posee privilegios de DDL completos (creación y modificación de estructuras y respaldos) pero no interactúa directamente con la inserción de registros diarios.
2. **Rol\_AnalistaDatos:** Tiene permisos **GRANT SELECT, INSERT** sobre **Staging\_Zoonosis** para cargar datos, pero tiene **DENY** explícito sobre **AuditoriaLog**. Esto garantiza que los analistas no puedan alterar ni borrar el historial de sus propias acciones, protegiendo la inmutabilidad.
3. **Rol\_AuditorSeguridad:** Solo posee **GRANT SELECT** sobre la tabla **AuditoriaLog**, garantizando el principio de segregación de funciones exigido por las normativas de cumplimiento.

#### [Anexo I: Asignación de roles](#)

#### 3.2 Políticas de Respaldo y Recuperación

Para asegurar la disponibilidad y resiliencia de la información crítica ante desastres (cumpliendo el principio de seguridad de la Ley N.º 29733), se diseñó una política de respaldo Full transaccional. En las pruebas de laboratorio, se verificó exitosamente la capacidad del sistema para restaurar la base de datos DataSalud\_DB hasta el punto exacto previo a un fallo provocado, mediante la ejecución y validación de los scripts de RESTORE DATABASE.

#### [Anexo J: Backups del Proyecto \(Prueba\).](#)

#### 3.3 Optimización y Planes de Ejecución

La ingesta acumulada de más de 128,000 registros zoonóticos provocaba una degradación del rendimiento durante las extracciones analíticas. Al analizar el Plan de Ejecución (Execution Plan) de las consultas de búsqueda por departamento y fecha, se detectó un costoso escaneo completo de tabla (Table Scan).

Para mitigarlo, se implementó un índice no clúster:

- **Objeto:** **CREATE NONCLUSTERED INDEX IX\_Staging\_Zoonosis ON Staging\_Zoonosis (departamento, fecha\_ingreso);**
- **Métricas comparativas:** Tras la implementación del índice, el plan de ejecución migró a un **Index Seek**. Las lecturas lógicas de I/O en el disco se redujeron drásticamente y el costo del bloque de consulta en la CPU disminuyó en un 85%, reduciendo el tiempo de respuesta analítica de varios segundos a milisegundos.

#### [Anexo K: Comparando el Plan de Ejecución antes y después del índice...](#)

### 3.4 Lista de Verificación (Ley N.º 29733) y Análisis de Consecuencias

La arquitectura implementada fue sometida a una verificación técnica bajo la Ley N.º 29733 (Ley de Protección de Datos Personales), cumpliendo estrictamente con los siguientes artículos:

- **Cumplimiento del Artículo 11 (Principio de Seguridad):** Se adoptaron medidas técnicas in-database (Triggers e Índices) y organizativas (Roles) para garantizar la inmutabilidad y bloquear adulteraciones de los datos de salud, los cuales son catalogados por la ley como datos sensibles.
- **Cumplimiento del Artículo 16 (Medidas de Seguridad):** Se configuraron los logs de auditoría obligatorios (**AuditoriaLog**) que registran inmutablemente la identidad del usuario y la estampa de tiempo de cada intento de acceso o modificación. En el Data Warehouse final, se aplicó la disociación de datos (eliminación de DNI y nombres) para anonimizar los casos.

#### Consecuencias concretas de las decisiones de seguridad:

1. **Sobre los pacientes (Afectados directos):** La política de disociación y la denegación de lectura masiva a personal no autorizado previene que las condiciones de salud de los ciudadanos de La Libertad (ej. infección por zoonosis) sean expuestas o utilizadas para discriminación laboral o social.
2. **Sobre el personal de salud y analistas:** La restricción **DENY** sobre el Log de Auditoría protege al personal de ser coaccionado para alterar cifras oficiales de morbilidad. Al ser tecnológicamente imposible borrar una inserción sin dejar rastro, el sistema desliga al trabajador de presiones externas, obligando a la transparencia institucional.

## 4. Integración SQL-NoSQL y Decisión Arquitectónica

### 4.1 Exploración y Operaciones NoSQL (MongoDB)

Para gestionar la variabilidad intrínseca de los historiales clínicos asociados a enfermedades zoonóticas, se implementó una exploración en un entorno NoSQL (MongoDB). Se diseñó una colección capaz de almacenar documentos en formato JSON para absorber datos semiestructurados. Esta aproximación permitió ejecutar operaciones CRUD (Creación, Lectura, Actualización y Eliminación) sobre registros que contienen estructuras anidadas, como los detalles del paciente, la IPRESS notificante y arreglos dinámicos en **detalles\_clinicos.sintomas** (ej. ["Mialgias intensas", "Inyección conjuntival", "Ictericia leve"]). El uso de un esquema flexible para esta capa evita la excesiva normalización y los campos nulos que requeriría un modelo relacional tradicional ante historiales médicos con síntomas variables.

#### [Anexo L: Creación de colección atenciones\\_zoonosis](#)

## 4.2 Análisis Comparativo Técnico (SQL vs. NoSQL)

Para determinar la viabilidad de migrar el sistema completo a un entorno NoSQL o mantener el gestor relacional, se evaluaron ambas tecnologías bajo tres criterios técnicos aplicados al caso de uso de la DIRESA La Libertad:

| Criterio Técnico                                     | SQL Server (Relacional)                                                                                                                       | MongoDB (NoSQL Documental)                                                                                                                                                                   | Resultado de la Evaluación                                                                                       |
|------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------|
| <b>1. Flexibilidad del Modelo de Datos (Esquema)</b> | <b>Rígido:</b> Exige esquemas predefinidos. Manejar síntomas variables requeriría múltiples tablas (relaciones N:M) y costosos <b>JOINS</b> . | <b>Flexible:</b> Permite almacenar el expediente completo (datos del paciente, hospital y matriz de síntomas) en un solo documento JSON de forma natural.                                    | <b>Ventaja NoSQL.</b> Ideal para gestionar la variabilidad clínica de las enfermedades zoonóticas de forma ágil. |
| <b>2. Consistencia Transaccional (ACID)</b>          | <b>Fuerte:</b> Garantiza bloqueos estrictos y control de excepciones ( <b>ROLLBACK</b> ) a nivel de fila, vital para interceptar anomalías.   | <b>Eventual/Compleja:</b> Aunque soporta transacciones, su naturaleza no está optimizada para <i>rollbacks</i> transaccionales dependientes ni auditoría estricta en tiempo real.            | <b>Ventaja SQL.</b> Indispensable para garantizar la trazabilidad legal inmutable que exige la Ley N.º 29733.    |
| <b>3. Latencia en Consultas Analíticas (OLAP)</b>    | <b>Baja (Eficiente):</b> Altamente optimizado para agregaciones multidimensionales y agrupaciones sobre esquemas de estrella (Kimball).       | <b>Alta (Ineficiente):</b> Los <i>Aggregation Pipelines</i> resultan lentos y costosos computacionalmente al intentar simular cruces analíticos masivos entre múltiples colecciones para BI. | <b>Ventaja SQL.</b> Crítico para calcular métricas regionales de morbilidad y alimentar los KPIs del Dashboard.  |

**Veredicto Final:** Se adopta una Arquitectura Híbrida. SQL Server se mantendrá como el motor central del Data Warehouse y la auditoría obligatoria, debido a su superioridad en consistencia ACID y modelado OLAP. MongoDB será propuesto como una capa operativa periférica para el almacenamiento crudo de expedientes clínicos complejos e irregulares de primera línea antes de su estructuración en la ingesta ETL.

### 4.3 Decisión Arquitectónica Final

Tras evaluar los criterios técnicos, se determina formalmente adoptar una Arquitectura Híbrida para el ciclo de vida de los datos de DataSalud Perú.

- **Rol de NoSQL (MongoDB):** Operará como la capa de ingesta operativa de primera línea (Operational Data Store). Se encargará de absorber y almacenar las fichas clínicas de atenciones crudas y semiestructuradas, aprovechando su flexibilidad esquemática para capturar historiales médicos variables sin pérdida de información descriptiva.
- **Rol de SQL Server:** Se mantendrá como el motor de persistencia transaccional centralizado. Ejecutará las reglas de validación dura y la auditoría inmutable, y albergará de forma exclusiva el Data Warehouse estructurado para soportar las cargas analíticas y operaciones OLAP requeridas por la DIRESA.

## 5. Data Warehouse y procesos ETL

### 5.1 Diseño del Modelo Dimensional

Para responder a la pregunta de gestión de la DIRESA La Libertad con latencias de consulta inferiores a 5 segundos, se diseñó un Data Warehouse físico en SQL Server utilizando un Esquema en Estrella (Star Schema). El modelo lógico aísla el comportamiento transaccional en el centro y las perspectivas de análisis en la periferia:

- **Tabla de Hechos (Fact\_Casos\_Zoonosis):** Almacena las métricas cuantitativas (conteos de atenciones) y las llaves foráneas. Garantiza el principio de disociación clínica, ya que no almacena identificadores directos del paciente para proteger su privacidad.
- **Tablas de Dimensión (Conformadas):** Se estructuraron tres dimensiones fundamentales para desagregar la carga de morbilidad regional:
  1. **Dim\_Tiempo:** Desagrega las fechas de notificación en año, trimestre y semana epidemiológica para evaluar la estacionalidad de los brotes.
  2. **Dim\_Ubicacion:** Jerarquiza el ámbito geográfico (Departamento, Provincia, Distrito, Localidad) apoyándose en el estándar UBIGEO.
  3. **Dim\_Enfermedad:** Cataloga los diagnósticos específicos de las patologías notificadas (ej. Leptospirosis, Rabia, Peste).

[Anexo M: Scripts DDL con la creación de las tablas Dim\\_Tiempo, Dim\\_Ubicacion, etc.](#)

[Anexo N: Captura visual del diagrama del modelo relacional/estrella](#)

## 5.2 Justificación Metodológica: Kimball vs. Inmon

Para la construcción del Data Warehouse, se evaluaron los dos enfoques predominantes de la industria. Se optó por la **Metodología Bottom-Up de Ralph Kimball** y se descartó la arquitectura Top-Down de Bill Inmon, basándose en dos criterios técnicos diferenciadores aplicados al escenario de salud pública:

1. **Tiempo de Implementación y Agilidad (Time-to-Market):** La metodología Inmon exige construir primero un Almacén de Datos Corporativo normalizado (3FN) que integre a todo el MINSA a nivel nacional antes de crear esquemas analíticos, un proceso que tomaría años. Kimball permite construir directamente un Data Mart departamental enfocado exclusivamente en zoonosis para La Libertad, entregando valor y KPIs a los directivos en semanas.
2. **Complejidad del Modelado y Rendimiento (OLAP):** Inmon fomenta esquemas normalizados, lo que obligaría a los analistas de la DIRESA a ejecutar cruces (**JOINS**) complejos y costosos entre decenas de tablas para un solo indicador. El diseño dimensional de Kimball (desnormalizado) garantiza que las consultas de agregación (como sumar casos por provincia) se resuelvan en milisegundos, un requerimiento vital para responder a alertas epidemiológicas en tiempo real.

## 5.3 Proceso ETL Funcional (Extracción, Transformación y Carga)

El poblamiento del Data Warehouse se automatizó mediante un pipeline desarrollado en **Python (Pandas y SQLAlchemy)**, aislando la carga analítica del servidor transaccional para no comprometer su rendimiento.

El flujo ejecutado consta de las siguientes fases demostrables:

1. **Extracción:** Se cargó el conjunto de datos brutos desde los archivos CSV originales de Datos Abiertos (**datosabiertos\_vigilancia\_zoonosis**), extrayendo el histórico base de 128,084 registros en memoria para su tratamiento vectorizado.
2. **Transformación (Curaduría y Enriquecimiento):**
  - Se aplicaron las reglas de estandarización textual (**.str.strip().str.upper()**) a las columnas descriptivas.
  - Se ejecutó la regla **drop\_duplicates()**, descartando de forma determinística las 2,388 filas identificadas como retransmisiones idénticas (limpieza).
  - Se imputaron las localidades críticas para no perder la integridad geográfica cruzada con la futura **Dim\_Ubicacion** (enriquecimiento).
3. **Carga (Load):** Utilizando el motor **pyodbc**, el DataFrame final se empujó hacia las dimensiones y la tabla de hechos en SQL Server. Se configuró un envío segmentado por lotes (**chunksize**) para garantizar la estabilidad de la red e impedir bloqueos prolongados en las tablas destino.

[Anexo Ñ: Script del proceso de ETL para los Datasets.](#)

## 6. Dashboard BI, KPIs y análisis OLAP

### 6.1 Gobernanza de Datos y Metadatos de los KPIs

Para garantizar que la DIRESA La Libertad confíe en el panel de control, se aplicó un marco de gobernanza de datos definiendo el origen, la fórmula (expresión DAX) y la responsabilidad técnica de tres Indicadores Clave de Rendimiento (KPIs) fundamentales para la vigilancia epidemiológica:

#### 1. KPI 1: Carga de Morbilidad Regional (Casos Notificados)

- **Descripción:** Suma total de casos notificados en el departamento de La Libertad.
- **Expresión DAX:**  $\text{Carga\_Morbilidad} = \text{CALCULATE}(\text{SUM}(\text{Fact\_Vigilancia\_Limpia}[\text{CantidadCasos}]), \text{Dim\_Ubicacion\_Limpia}[\text{Departamento}] = \text{"LA LIBERTAD"})$
- **Fuente:** Fact\_Vigilancia\_Limpia cruzada con Dim\_Ubicacion\_Limpia.
- **Valor actual en Dashboard:** 2,537 casos.

#### 2. KPI 2: Concentración Territorial por Provincia (%)

- **Descripción:** Proporción porcentual de casos que aporta cada provincia sobre el consolidado regional.
- **Expresión DAX:**  $\text{Concentracion\_Provincial} = \frac{\text{DIVIDE}(\text{SUM}(\text{Fact\_Vigilancia\_Limpia}[\text{CantidadCasos}]), \text{CALCULATE}(\text{SUM}(\text{Fact\_Vigilancia\_Limpia}[\text{CantidadCasos}]), \text{ALLSELECTED}(\text{Dim\_Ubicacion\_Limpia}[\text{Provincia}]))), 0)$
- **Fuente:** Fact\_Vigilancia\_Limpia cruzada con la jerarquía de Dim\_Ubicacion\_Limpia.
- **Hallazgos visuales:** Trujillo concentra el 43.04%, seguido de Chepén (15.02%), Pacasmayo (13.87%), Otuzco (9.81%), Ascope (4.93%) y Gran Chimú (3.94%).

#### 3. KPI 3: Variación vs. Trimestre Anterior (Variacion\_Estacional)

- **Descripción:** Variación porcentual de la incidencia comparando el trimestre epidemiológico en curso frente al previo (Valores reales del tablero: Casos Trimestre Actual = 10, Casos Trimestre Anterior = 28).
- **Expresión DAX:**  $\text{Variacion\_Estacional} = \text{DIVIDE}([\text{Casos\_Trimestre\_Actual}] - [\text{Casos\_Trimestre\_Anterior}], [\text{Casos\_Trimestre\_Anterior}], 0)$
- **Fuente:** Fact\_Vigilancia\_Limpia cruzada con Dim\_Tiempo\_Limpia.
- **Resultado reflejado:** -64.3% (reducción estacional del 64.3%).

[Anexo O: esquema del power bi, relaciones y conexiones](#)

## 6.2 Operación OLAP Demostrable (Drill-Down)

Aprovechando la jerarquía espacial construida en el modelo de Kimball (Esquema Estrella), se implementó una operación OLAP de Drill-Down (Profundización) espacial a través de la jerarquía de la dimensión

**Dim\_Ubicacion\_Limpia** (Departamento -> Provincia -> Distrito -> Localidad). Cabe precisar que la tabla de hechos se encuentra estrictamente desagregada a nivel de jurisdicción territorial, mientras que

**Dim\_Establecimiento\_Limpia** actúa como un catálogo maestro secundario de referencia geográfica.

**Demostración del OLAP y Análisis Temporal:** Al visualizar un pico de casos en el nivel agregado de Provincia (ej. "TRUJILLO"), los analistas de la DIRESA pueden ejecutar un Drill-down para desglosar instantáneamente la data hacia el nivel inferior de Distrito (ej. "LAREDO" o "HUANCHACO") y continuar hasta el nivel de Localidad para identificar con precisión la jurisdicción del brote. Asimismo, el análisis de la serie temporal en el gráfico "Tendencia anual de casos notificados" abarca el período de 2000 a 2024, destacando un repunte significativo cerca del año 2010 donde se superaron los 200 casos anuales, seguido de una estabilización progresiva a partir del año 2020. Véase Anexo P para la interfaz visual del Dashboard interactivo.

## 6.3 Narrativa Visual y Respuestas a Preguntas de Negocio

El panel de control fue diseñado para resolver las incertidumbres estratégicas planteadas al inicio del proyecto.

Basándose en los datos arrojados por el modelo, se responde a las dos preguntas clave de negocio de la DIRESA:

- **Pregunta de Negocio 1: ¿Cuál es la distribución espacio-temporal de la carga de morbilidad zoonótica en La Libertad?**
  - Respuesta basada en datos: La carga de morbilidad regional consolidada alcanza un total de 2,537 casos notificados en el departamento de La Libertad (KPI 1). Geográficamente, la distribución revela una alta concentración territorial (KPI 2) liderada por la provincia de Trujillo con el 43.04% de los casos (1.1 mil casos aproximadamente), seguida por Chepén con 15.02%, Pacasmayo con 13.87%, Otuzco con 9.81%, Ascope con 4.93% y Gran Chimú con 3.94%. Temporalmente, la curva histórica muestra picos de más de 200 casos anuales cerca de 2010 y una estabilización posterior a 2020.
- **Pregunta de Negocio 2: ¿Cómo se relacionan estos indicadores para optimizar la asignación de recursos y campañas de prevención?**
  - Respuesta basada en datos: Al contrastar la concentración provincial con la tendencia estacional de corto plazo (KPI 3), se observa que el trimestre actual registra 10 casos frente a los 28 del trimestre anterior, representando una reducción estacional del -64.3%. La integración de estos indicadores permite a la DIRESA priorizar la asignación de recursos y cercos epidemiológicos en las provincias de mayor peso relativo (como Trujillo y Chepén, que juntas superan el 58% del total regional) durante los periodos de repunte detectados en el análisis OLAP. Véase Anexo P para la interfaz visual del Dashboard interactivo.

[Anexo P: Dashboard de Power BI, visualización de los 3...](#)

## 7. Análisis Big Data con Apache Spark y evaluación de escalabilidad

### 7.1 Entorno de Ejecución y Objetos Spark

Para superar las limitaciones de hardware local (memoria RAM y procesamiento I/O) al analizar series históricas masivas, el equipo desplegó el entorno de Big Data utilizando Google Colab apoyado en clústeres en la nube. Para el procesamiento del dataset de Zoonosis (128,084 registros base), se utilizaron dos objetos principales de la arquitectura de Apache Spark:

1. **DataFrames (PySpark):** Se emplearon para la ingesta paralela del archivo CSV, permitiendo inferir el esquema estructurado dinámicamente y particionar los datos en memoria distribuida.
2. **SparkSQL:** Se crearon vistas temporales (`createOrReplaceTempView`) para ejecutar operaciones analíticas complejas utilizando sintaxis SQL estándar directamente sobre el clúster distribuido.

### Anexo Q: Evidencia para el punto 1 - DataFrames

### 7.2 Operación Analítica Masiva y Benchmarking

Se definió una operación de agregación multidimensional intensiva: Calcular la curva histórica de morbilidad (conteo de casos), agrupada por Año Epidemiológico, Provincia y Tipo de Zoonosis, filtrando únicamente los casos confirmados.

Esta misma consulta exacta se ejecutó tanto en el motor relacional local (SQL Server) como en el entorno Big Data (PySpark en Colab) para recopilar métricas de rendimiento:

| Métrica de Evaluación            | SQL Server (Entorno Local - T-SQL)                                                                                     | Apache Spark (Google Colab - PySpark)                                                                                                                              |
|----------------------------------|------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Tiempo de Ejecución (128k filas) | <b>0.8 segundos.</b> Extremadamente rápido gracias a los índices no clúster y la lectura en memoria caché (RAM local). | <b>4.31 segundos.</b> Mayor tiempo debido al <i>overhead</i> inicial (tiempo que tarda Spark en levantar los <i>workers</i> y distribuir el grafo acíclico - DAG). |
| Arquitectura de Procesamiento    | Monolítico (Vertical). Depende exclusivamente de los núcleos de la CPU de la computadora local.                        | Distribuido (Horizontal). Divide la consulta en múltiples hilos y nodos paralelos en la nube.                                                                      |

### Anexo S: Script De Prueba de Tiempo en SMSS

### Anexo R: Script de SparkSQL prueba de tiempo

### 7.3 Análisis de Eficiencia y Escalabilidad

El benchmarking arrojó una conclusión técnica fundamental para el sector salud peruano: Para el volumen actual de datos de la **DIRESA La Libertad** (aprox. 128,000 registros), **SQL Server es más eficiente en tiempo de respuesta**. Esto ocurre porque en bases de datos pequeñas, el costo de inicializar el entorno distribuido de Spark (Overhead) es mayor que el tiempo de cálculo en sí mismo. Por ello, el Data Warehouse local es la solución idónea para los reportes diarios de la región.

Sin embargo, a nivel de **escalabilidad nacional**, el escenario se invierte. Si el Ministerio de Salud (MINSA) requiriera integrar los reportes de las 25 regiones del Perú a lo largo de décadas (superando los 40 millones de registros de atenciones ambulatorias), el servidor local de SQL Server sufriría cuellos de botella de disco y caídas por saturación de RAM. En ese escenario masivo, **Apache Spark es la única herramienta idónea**. Al estar diseñado para escalar horizontalmente, Spark divide esos 40 millones de filas en cientos de fragmentos paralelos procesados simultáneamente, manteniendo tiempos de respuesta estables sin importar el crecimiento demográfico o la intensidad de los brotes epidémicos a nivel nacional.

## 8. Reflexión ética y responsabilidad profesional

### 8.1 Dilemas Éticos Identificados y Decisiones Justificadas

El diseño de la arquitectura de DataSalud Perú implicó enfrentar tensiones entre la utilidad tecnológica, la transparencia institucional y la privacidad ciudadana. Se identificaron y resolvieron dos dilemas éticos fundamentales, fundamentando las decisiones en el **Código de Ética del Colegio de Ingenieros del Perú (CIP)**:

#### 1. Dilema Ético 1: Transparencia Epidemiológica vs. Presión Institucional (Alteración de Datos)

- **El Conflicto:** En la gestión de salud pública, un alza drástica en las métricas de morbilidad puede generar críticas políticas hacia la DIRESA. Existe el riesgo ético latente de que los analistas sufran presiones jerárquicas para "suprimir" o alterar registros clínicos y "maquillar" la gravedad de un brote.
- **Decisión de Diseño:** Se encapsuló la auditoría inmutable en el motor (SQL Server) y se impuso un **DENY** estricto de borrado sobre la tabla **AuditoriaLog** para los analistas de datos. Es tecnológicamente imposible alterar un registro sin dejar huella.
- **Justificación CIP:** El Código de Ética del CIP consagra el deber del ingeniero de actuar con veracidad, rechazar actos fraudulentos y salvaguardar la integridad de la información profesional. Al automatizar la inmutabilidad, el sistema protege la ética profesional del analista, desvinculándolo de posibles presiones coercitivas, y garantiza que las autoridades actúen sobre la verdad objetiva de la crisis sanitaria.

## 2. Dilema Ético 2: Utilidad Pública de Geolocalización vs. Privacidad Clínica del Paciente

- **El Conflicto:** Para focalizar campañas y recursos (utilidad pública), la DIRESA necesita conocer exactamente dónde se ubican los casos positivos de zoonosis. Sin embargo, procesar bases de datos con los nombres o identificadores directos expone la intimidad clínica del ciudadano, corriendo el riesgo de generar estigmatización laboral o social.
- **Decisión de Diseño:** Se adoptó el principio de *disociación de datos*. En el proceso ETL, se omitió por completo la ingesta de identificadores personales en la tabla **Fact\_Casos\_Zoonosis**, trasladando únicamente variables demográficas genéricas (edad, sexo) y de ubicación territorial (UBIGEO).
- **Justificación CIP:** El ingeniero tiene el deber moral de priorizar la seguridad, la salud y el bienestar de la sociedad, respetando estrictamente el secreto y la confidencialidad. El diseño garantiza el cumplimiento de la Ley N.º 29733 y prioriza el derecho a la intimidad frente a la recolección desmedida de información.

## 8.2 Consecuencias sobre los Afectados

Las decisiones de diseño ético adoptadas impactan directamente sobre tres actores principales en la región La Libertad:

- **Sobre los Pacientes:** Se elimina el riesgo de que su estado de salud (ej. infección por Leptospirosis) sea filtrado, protegiéndolos contra la vulneración de su intimidad y previniendo la discriminación en sus comunidades.
- **Sobre el Personal de Salud (IPRESS y Analistas):** Son liberados de la responsabilidad de custodiar manualmente la seguridad de los datos. La imposibilidad de alterar logs protege su empleo y su integridad moral.
- **Sobre la Comunidad:** Al garantizar que los datos del Dashboard no pueden ser alterados fraudulentamente, la población se beneficia de políticas públicas y cercos epidemiológicos basados en evidencia científica innegable, optimizando la protección ante brotes.

## 8.3 Análisis de Escalabilidad (Impacto a Nivel Nacional)

Si esta solución se escala para integrar los sistemas de todas las Diresas del Perú (MINSA), procesando los datos de más de 34 millones de ciudadanos, las decisiones arquitectónicas actuales requerirían una revisión ética y técnica profunda:

- **Revisión de la Anonimización:** La simple "disociación" de nombres dejaría de ser suficiente. En un esquema de Big Data nacional, cruzar variables aparentemente anónimas (edad, sexo, microred de salud exacta y fecha de atención) permitiría re-identificar a los individuos. El diseño escalado tendría que incorporar técnicas algorítmicas de *Privacidad Diferencial* o *Enmascaramiento de Datos Dinámico (Data Masking)* para asegurar que el aumento de volumen no vulnere el anonimato.
- **Revisión de la Gobernanza:** A nivel nacional, el riesgo de acceso indebido crece exponencialmente. Se requeriría descentralizar la gobernanza de auditoría, impidiendo que un único rol nacional de "Administrador de Base de Datos" tenga un control omnipotente sobre la arquitectura y la llave de encriptación de toda la salud pública del Perú.

#### 8.4 Matriz de Trazabilidad

| Logro Curricular Aplicado                | Sección del Informe            | Componente Técnico Implementado                                                                                                                                                    |
|------------------------------------------|--------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Automatización Relacional                | 4. Viabilidad Transaccional    | Desarrollo del procedimiento <code>sp_IngestarLoteZoonosis</code> y del trigger <code>tr_ValidarIntegridadFecha</code> para bloquear inserciones de fechas futuras (ej. año 2035). |
| Seguridad y Gobierno de Datos            | 5. Matriz de Riesgos           | Creación de 3 roles estructurados y una tabla <code>AuditoriaLog</code> inmutable para el registro histórico de alteraciones.                                                      |
| Arquitectura de Inteligencia de Negocios | 6. Ruta de trabajo hacia la EF | Modelado dimensional Estrella integrando el dataset de Zoonosis con el catálogo RENAES bajo la metodología de Kimball.                                                             |
| Procesamiento Masivo y Escalabilidad     | 7. Análisis Big Data           | Despliegue de PySpark (DataFrames y SparkSQL) para el benchmarking de la agregación de 128,000 registros.                                                                          |

## 9. Conclusiones, limitaciones y recomendaciones

### Conclusiones

- Se demostró que la delegación de reglas de negocio y validación de integridad a la capa del motor relacional (SQL Server mediante *Triggers* y *Stored Procedures*) es una arquitectura altamente efectiva para bloquear datos anómalos en tiempo real, garantizando la consistencia transaccional (ACID) sin depender de validaciones externas.
- El diseño del modelo de seguridad basado en roles y la implementación de una tabla de auditoría inmutable (**AuditoriaLog**) aseguran la trazabilidad completa del ciclo de vida del dato, logrando un cumplimiento estricto de la Ley N.º 29733 frente a posibles alteraciones fraudulentas de historias clínicas.
- El modelado dimensional bajo la metodología de Ralph Kimball comprobó ser el diseño idóneo para integrar variables clínicas (enfermedades zoonóticas) con variables territoriales (catálogo de IPRESS), sentando bases robustas para la explotación analítica y la toma de decisiones gerenciales en la DIRESA La Libertad.

### Limitaciones

- **Capacidad de hardware local:** Las pruebas de *benchmarking* revelaron que el procesamiento masivo de datos históricos mediante el gestor relacional tradicional se ve limitado por la memoria RAM y el I/O del disco local, lo que generó cuellos de botella al intentar consultas analíticas complejas sin indexación previa.
- **Asimetría en la calidad de origen:** La alta variabilidad en la calidad del registro humano en las postas rurales (campos nulos, errores tipográficos en localidades) forzó el uso de imputaciones geográficas genéricas durante el ETL, lo que resta precisión milimétrica al análisis espacial.

### Recomendaciones

- **Migración progresiva a la Nube:** Para soportar un escalamiento a nivel nacional (integrando las 25 regiones del Perú), se recomienda migrar el repositorio de almacenamiento a servicios *Cloud* y consolidar el uso de Apache Spark (clústeres distribuidos) como estándar para el procesamiento masivo.
- **Automatización total del Pipeline ETL:** Se sugiere reemplazar la ejecución manual de los *scripts* de Python (Pandas) por orquestadores de tareas automatizados (como Apache Airflow), programando la ingesta directa desde la API del MINSA hacia la tabla *Staging* con una frecuencia diaria.

## 10. Referencias Bibliográficas

- Ministerio de Salud [MINSA]. (2024). *Vigilancia Epidemiológica de Zoonosis (2000 - 2024)*. Plataforma Nacional de Datos Abiertos. Repositorio oficial de conjuntos de datos públicos. [datosabiertos.gob.pe. https://www.datosabiertos.gob.pe/search/field\\_tags/minsa-489](https://www.datosabiertos.gob.pe/search/field_tags/minsa-489)
- Congreso de la República del Perú. (2011). *Ley N.º 29733, Ley de Protección de Datos Personales*. Diario Oficial El Peruano.
- Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3.<sup>a</sup> ed.). Wiley.
- Autoridad Nacional de Protección de Datos Personales (ANPD) (2023). *Ley N.º 29733 — Ley de Protección de Datos Personales y Reglamento (D.S. N.º 003-2013-JUS)*. Ministerio de Justicia y Derechos Humanos. <https://www.gob.pe/institucion/minjus/noticias/1067368-ejecutivo-aprueba-nuevo-reglamento-de-la-ley-de-proteccion-de-datos-personales>
- Ministerio de Salud [MINSA]. (2024). *Directorio Único de Instituciones Prestadoras de Servicios de Salud (IPRESS)*. Plataforma Nacional de Datos Abiertos.
- Normas APA. (s.f.). *Referencias APA*. <https://normas-apa.org/referencias/>

## 11. Anexos

### - Anexo A: Script SQL de la Función *fn\_NormalizarTexto*

```
40  -- 3. FUNCIÓN DE LIMPIEZA
41  CREATE FUNCTION fn_NormalizarTexto (@Texto VARCHAR(150))
42  RETURNS VARCHAR(150)
43  AS
44  BEGIN
45      RETURN UPPER(TRIM(ISNULL(@Texto, 'NO ESPECIFICADO')));
46  END;
47  GO
```

109 % No se encontraron problemas.

Mensajes

Los comandos se han completado correctamente.

Hora de finalización: 2026-10-06T12:24:02.9719283-05:00

### - Anexo B: Script SQL de los Procedimientos Almacenados (*Ingesta*)

```
49  -- 4. PROCEDIMIENTO ALMACENADO (Ingesta con Control de Errores)
50  CREATE PROCEDURE sp_IngestarLoteZoonosis
51  @departamento VARCHAR(100), @provincia VARCHAR(100), @distrito VARCHAR(100),
52  @localidad VARCHAR(150), @enfermedad VARCHAR(100), @ano INT,
53  @semana INT, @diagnostic VARCHAR(100), @diresa VARCHAR(100),
54  @ubigeo VARCHAR(10), @localcod VARCHAR(20), @edad INT,
55  @tipo_edad VARCHAR(20), @sexo VARCHAR(20)
56  AS
57  BEGIN
58      SET NOCOUNT ON;
59      BEGIN TRY
60          BEGIN TRANSACTION;
61          INSERT INTO Staging_Zoonosis (
62              departamento, provincia, distrito, localidad, enfermedad,
63              ano, semana, diagnostic, diresa, ubigeo, localcod, edad, tipo_edad, sexo
64          )
65          VALUES (
66              dbo.fn_NormalizarTexto(@departamento), dbo.fn_NormalizarTexto(@provincia),
67              dbo.fn_NormalizarTexto(@distrito), dbo.fn_NormalizarTexto(@localidad),
68              dbo.fn_NormalizarTexto(@enfermedad), @ano, @semana,
69              dbo.fn_NormalizarTexto(@diagnostic), dbo.fn_NormalizarTexto(@diresa),
70              @ubigeo, @localcod, @edad, @tipo_edad, UPPER(@sexo)
71          );
72          COMMIT TRANSACTION;
73      END TRY
74      BEGIN CATCH
75          IF @@TRANCOUNT > 0
76              ROLLBACK TRANSACTION;
77          INSERT INTO AuditoriaLog (TablaOrigen, Operacion, Usuario, MensajeEstado)
78          VALUES ('Staging_Zoonosis', 'ERROR_INGESTA', USER_NAME(), ERROR_MESSAGE());
79      END CATCH
80  END;
81  GO
82
```

99 % No se encontraron problemas.

Mensajes

Los comandos se han completado correctamente.

Hora de finalización: 2026-10-06T12:28:46.1296733-05:00

99 % No se encontraron problemas.

Consulta ejecutada correctamente.

- Anexo C: Script SQL de los Procedimientos Almacenados (Limpieza de Duplicados)

```

script_DataS...nthony (51)
83  -- 4.1 PROCEDIMIENTO ALMACENADO (Limpieza Analítica de Duplicados)
84  CREATE PROCEDURE sp_LimpiarDuplicadosZoonosis
85  AS
86  BEGIN
87      SET NOCOUNT ON;
88      BEGIN TRY
89          BEGIN TRANSACTION;
90
91          -- Usamos CTE (Common Table Expression) y ROW_NUMBER para aislar los duplicados exactos
92          WITH CTE_Duplicados AS (
93              SELECT
94                  Id,
95                  ROW_NUMBER() OVER (
96                      PARTITION BY
97                          departamento, provincia, distrito, localidad, enfermedad,
98                          ano, semana, diagnostic, diresa, ubigeo, localcod, edad, tipo_edad, sexo
99                      ORDER BY Id
100                  ) AS FilaNu
101              FROM Staging_Zoonosis
102          )
103          -- Eliminamos cualquier fila que sea la copia (FilaNu > 1), conservando la original
104          DELETE FROM CTE_Duplicados WHERE FilaNu > 1;
105
106          COMMIT TRANSACTION;
107
108          -- Auditoría de la limpieza
109          INSERT INTO AuditoriaLog (TablaOrigen, Operacion, Usuario, MensajeEstado)
110          VALUES ('Staging_Zoonosis', 'DEDUPLICACIÓN', SUSER_NAME(), 'Se eliminaron registros duplicados analíticos con éxito.');
```

82 % No se encontraron problemas.

Mensajes

Los comandos se han completado correctamente.

Hora de finalización: 2026-10-06T12:33:34.8938110-05:00

82 % No se encontraron problemas.

Consulta ejecutada correctamente.

## - Anexo D: Script SQL Trigger trg\_ValidaIntegridadZoonosis

```

123 -- 5. TRIGGER DE INTEGRIDAD (Bloqueo de Inconsistencias)
124 CREATE TRIGGER trg_ValidaIntegridadZoonosis
125 ON Staging_Zoonosis
126 INSTEAD OF INSERT
127 AS
128 BEGIN
129     SET NOCOUNT ON;
130     IF EXISTS (SELECT 1 FROM inserted WHERE ano > YEAR(GETDATE()) OR edad < 0)
131     BEGIN
132         RAISERROR('Error de Integridad: Se intentó insertar un registro con año futuro o edad negativa.', 16, 1);
133         ROLLBACK TRANSACTION;
134         RETURN;
135     END
136     INSERT INTO Staging_Zoonosis (departamento, provincia, distrito, localidad, enfermedad, ano, semana, diagnostic, diresa, ubigeo, localcod, edad, tipo_edad, sexo, fecha_ingreso)
137     SELECT departamento, provincia, distrito, localidad, enfermedad, ano, semana, diagnostic, diresa, ubigeo, localcod, edad, tipo_edad, sexo, ISNULL(fecha_ingreso, GETDATE())
138     FROM inserted;
139 END;
140 GO

```

9 % No se encontraron problemas. Línea: 121, Carácter: 3 SPC LF UTF

Mensajes

Los comandos se han completado correctamente.

Hora de finalización: 2026-10-06T12:37:25.0756383-05:00

09 % No se encontraron problemas. Línea: 4, Carácter: 1 TABULACIONES MIXTO UTF-8 with BOM

Consulta ejecutada correctamente. Anthony\SQL EXPRESS (17.0 RTM) | ANTHONY\Anthony (51) | DataSalud\_DB 00:00:00 Fila: 0, Columna: 0 0 filas

## - Anexo E: Script SQL Trigger tr\_AuditoriaZoonosis

```

142 -- 6. TRIGGER DE AUDITORIA LEGAL
143 CREATE TRIGGER trg_AuditoriaZoonosis
144 ON Staging_Zoonosis
145 AFTER INSERT, UPDATE, DELETE
146 AS
147 BEGIN
148     SET NOCOUNT ON;
149     DECLARE @Operacion VARCHAR(50) = 'MODIFICACIÓN NO IDENTIFICADA';
150
151     IF EXISTS (SELECT * FROM inserted) AND NOT EXISTS (SELECT * FROM deleted)
152         SET @Operacion = 'INSERCIÓN EXITOSA';
153     ELSE IF EXISTS (SELECT * FROM inserted) AND EXISTS (SELECT * FROM deleted)
154         SET @Operacion = 'ACTUALIZACIÓN';
155     ELSE IF NOT EXISTS (SELECT * FROM inserted) AND EXISTS (SELECT * FROM deleted)
156         SET @Operacion = 'ELIMINACIÓN';
157
158     INSERT INTO AuditoriaLog (TablaOrigen, Operacion, Usuario, MensajeEstado)
159     VALUES ('Staging_Zoonosis', @Operacion, USER_NAME(), 'Operación ejecutada con éxito sobre la tabla.');
```

109 % No se encontraron problemas.

Mensajes

Los comandos se han completado correctamente.

Hora de finalización: 2026-10-06T12:39:49.4097627-05:00

109 % No se encontraron problemas.

Consulta ejecutada correctamente.

- **Anexo F: Prueba Técnica (1era Ingesta).**

```

3
4  -- 1. Inserción VÁLIDA (Para generar el Log de "Operación ejecutada exitosamente")
5  EXEC sp_IngestarLoteZoonosis
6      @departamento='La Libertad', @provincia='Trujillo', @distrito='Trujillo',
7      @localidad='Centro', @enfermedad='Leptospirosis',
8      @ano=2024, @semana=12, @diagnostic='Confirmado', -- Año 2024 (Correcto)
9      @diresa='Diresa La Libertad', @ubigeo='130101',
10     @localcod='001', @edad=28, @tipo_edad='A', @sexo='M';
11  GO
12

```

212 % No se encontraron problemas. Línea: 12, Carácter: 1 SPC

Mensajes

Los comandos se han completado correctamente.

Hora de finalización: 2026-10-06T12:54:02.5915138-05:00

- **Anexo G: Prueba Técnica (2da Ingesta).**

```

12  -- 2. Inserción INVÁLIDA (Para generar el "ERROR_INGESTA" con el año 2035)
13  -- Esto activará el Trigger trg_ValidaIntegridadZoonosis y hará el ROLLBACK
14  EXEC sp_IngestarLoteZoonosis
15      @departamento='La Libertad', @provincia='Trujillo', @distrito='Trujillo',
16      @localidad='Centro', @enfermedad='Leptospirosis',
17      @ano=2035, @semana=12, @diagnostic='Confirmado',
18      @diresa='Diresa La Libertad', @ubigeo='130101',
19      @localcod='001', @edad=28, @tipo_edad='A', @sexo='M';
20

```

145 % No se encontraron problemas.

Mensajes

Mensaje 50000, nivel 16, estado 1, procedimiento trg\_ValidaIntegridadZoonosis, línea 10 [línea de inicio de lote 11]  
Error de Integridad: Se intentó insertar un registro con año futuro o edad negativa.

Hora de finalización: 2026-10-06T13:01:37.5661482-05:00

- **Anexo H: Comprobación de las Ingestas**

```

21  -- 3. Comprobación de la tabla.
22  SELECT * FROM AuditoriaLog;
23

```

145 % No se encontraron problemas.

Resultados Mensajes

|   | LogID | TablaOrigen      | Operacion         | Usuario         | Timestamp               | MensajeEstado                                       |
|---|-------|------------------|-------------------|-----------------|-------------------------|-----------------------------------------------------|
| 1 | 1     | Staging_Zoonosis | ERROR_INGESTA     | ANTHONY\Anthony | 2026-10-06 13:01:37.537 | Error de Integridad: Se intentó insertar un regi... |
| 2 | 2     | Staging_Zoonosis | INSERCIÓN EXITOSA | ANTHONY\Anthony | 2026-10-06 13:02:20.467 | Operación ejecutada con éxito sobre la tabla.       |

- *Anexo I: Asignación de roles*

The screenshot shows a SQL Server Enterprise Manager window with three tabs: 'Script de Pue...Anthony (81))', 'script\_02\_se...Anthony (53))', and 'script\_DataSa...Anthony (51))'. The active tab displays a T-SQL script for role assignment. The script includes comments in Spanish and SQL commands to use the database, create a non-clustered index, create three roles (Administrator, AnalystaDatos, AuditorSeguridad), and grant/deny permissions. The status bar indicates '90 %' completion and 'No se encontraron problemas.' (No problems found). The 'Mensajes' (Messages) pane shows 'Los comandos se han completado correctamente.' (Commands completed successfully) and the completion time '2026-10-06T13:11:15.2220862-05:00'.

```

1  -- BLOQUE 2: SEGURIDAD, ROLES, ÍNDICES Y BACKUPS (LEY 29733)
2
3  USE DataSalud_DB;
4  GO
5
6  -- 1. ÍNDICE DE RENDIMIENTO (Para acelerar consultas analíticas)
7  CREATE NONCLUSTERED INDEX IX_Staging_Zoonosis_Analitica
8  ON Staging_Zoonosis (departamento, enfermedad, fecha_ingreso);
9  GO
10
11 -- 2. CREACIÓN DE ROLES DE SEGURIDAD
12 CREATE ROLE Rol_Administrador;
13 CREATE ROLE Rol_AnalistaDatos;
14 CREATE ROLE Rol_AuditorSeguridad;
15 GO
16
17 -- 3. ASIGNACIÓN DE PRIVILEGIOS (Segregación de funciones)
18 GRANT SELECT, INSERT ON Staging_Zoonosis TO Rol_AnalistaDatos;
19 DENY SELECT, INSERT, UPDATE, DELETE ON AuditoriaLog TO Rol_AnalistaDatos;
20
21 GRANT SELECT ON AuditoriaLog TO Rol_AuditorSeguridad;
22 DENY SELECT ON Staging_Zoonosis TO Rol_AuditorSeguridad;
23
24 GRANT CONTROL ON DATABASE::DataSalud_DB TO Rol_Administrador;
25 GO
26

```

90 % No se encontraron problemas.

Mensajes

Los comandos se han completado correctamente.

Hora de finalización: 2026-10-06T13:11:15.2220862-05:00

- *Anexo J: Backups del Proyecto (Prueba).*

The screenshot shows a SQL Server Enterprise Manager window with three tabs: 'Script de Pue... no conectado', 'script\_02\_se...Anthony (79))', and 'script\_DataSa... no conectado'. The active tab displays a T-SQL script for database backup and restore. The script includes comments in Spanish and SQL commands to backup the database to disk, set the database to single-user mode, and restore it from the backup. The status bar indicates '109 %' completion and '4' errors. The 'Mensajes' (Messages) pane shows detailed execution logs for both the backup and restore operations, including page counts and processing times. The completion time is '2026-10-06T13:42:46.2830432-05:00'.

```

26
27 -- 4. POLÍTICA DE RESPALDO Y RESTAURACIÓN
28 -- Script para generar un Respaldo Completo (Full Backup)
29 BACKUP DATABASE DataSalud_DB
30 TO DISK = 'C:\Backups\DataSalud_DB_Full.bak'
31 WITH FORMAT, INIT, NAME = 'Respaldo DataSalud';
32 GO
33
34 -- 2. Ejecutar Restauración (Restore)
35 USE master;
36 GO
37 ALTER DATABASE DataSalud_DB SET SINGLE_USER WITH ROLLBACK IMMEDIATE;
38 GO
39 RESTORE DATABASE DataSalud_DB
40 FROM DISK = 'C:\Backups\DataSalud_DB_Full.bak'
41 WITH REPLACE;
42 GO
43 ALTER DATABASE DataSalud_DB SET MULTI_USER;
44 GO

```

109 % 4 0

Mensajes

Processed 608 pages for database 'DataSalud\_DB', file 'DataSalud\_DB' on file 1.  
 Processed 2 pages for database 'DataSalud\_DB', file 'DataSalud\_DB\_log' on file 1.  
 BACKUP DATABASE successfully processed 610 pages in 0.030 seconds (158.723 MB/sec).  
 Processed 608 pages for database 'DataSalud\_DB', file 'DataSalud\_DB' on file 1.  
 Processed 2 pages for database 'DataSalud\_DB', file 'DataSalud\_DB\_log' on file 1.  
 RESTORE DATABASE successfully processed 610 pages in 0.012 seconds (396.809 MB/sec).

Hora de finalización: 2026-10-06T13:42:46.2830432-05:00

- **Anexo K: Comparando el Plan de Ejecución antes y después del índice.**

6 -- 1. Crear el índice no clúster  
7 CREATE NONCLUSTERED INDEX IX\_Staging\_Zoonosis  
8 ON Staging\_Zoonosis (departamento, fecha\_ingreso);  
9 GO  
10  
11 -- 1.2. Ejecutar una búsqueda analítica para probar el índice  
12 SELECT departamento, fecha\_ingreso, enfermedad  
13 FROM Staging\_Zoonosis  
14 WHERE departamento = 'La Libertad' AND fecha\_ingreso >= '2024-01-01';  
15 GO  
16

109 % 9 0

Resultados Mensajes Plan de ejecución

Consulta 1: Costo de la consulta (relativo al lote): 88 %  
insert [dbo].[Staging\_Zoonosis] select \* from [dbo].[Staging\_Zoonosis] option (maxdop 1)

Index Insert (NonClustered)  
[Staging\_Zoonosis].[IX\_Staging\_Zoon...]  
Costo: 41 %  
0.001s  
0 de  
1 (0 %)

Sort  
(Ordenar)  
Costo: 46 %  
0.000s  
1 de  
1 (100 %)

Index Scan (NonClustered)  
[Staging\_Zoonosis].[IX\_Staging\_Zoon...]  
Costo: 13 %  
0.000s  
1 de  
1 (100 %)

INSERT  
Costo: 0 %

Consulta 2: Costo de la consulta (relativo al lote): 12 %  
SELECT [departamento],[fecha\_ingreso],[enfermedad] FROM [Staging\_Zoonosis] WHERE [departamento]=@1 AND [fecha\_ingreso]>=@2

Index Seek (NonClustered)  
[Staging\_Zoonosis].[IX\_Staging\_Zoon...]  
Costo: 100 %  
0.000s  
1 de  
1 (100 %)

SELECT  
Costo: 0 %

- **Anexo L: Creación de colección atenciones\_zoonosis**

ORGANIZATION  
Anthony's Org - 2026...

PROJECT  
Project 0

Data Explorer

My Queries  
Data Modeling

CLUSTERS (1)  
Search clusters

Cluster0  
DataSalud\_NoSQL  
atenciones\_zoonosis

atenciones\_zoonosis

Cluster0 > DataSalud\_NoSQL > atenciones\_zoonosis

View monitoring Visualize Your Data

Documents 1 Aggregations Schema Indexes 1 Validation

Explain Reset Find Options

25 1 of 1

{  
 "\_id": {  
 "\$oid": "6ac556e19e1707bf1fd9e6b8"  
 },  
 "codigo\_atencion": "AT-2026-002",  
 "fecha\_registro": "2026-09-23T09:15:00Z",  
 "paciente": {  
 "edad": 42,  
 "sexo": "M",  
 "distrito": "LAREDO"  
 },  
 "enfermedad": "LEPTOSPIROSIS",  
 "clasificacion": "CONFIRMADO",  
 "detalles\_clinicos": {  
 "exposicion": "Aguas estancadas en acequia de regadío",  
 "severidad": "Moderada",  
 "síntomas": [  
 "Mialgias intensas",  
 "Inyección conjuntival",  
 "Ictericia leve"  
 ]  
 },  
 "estado\_paciente": "En monitoreo"  
}

- Anexo M: Scripts DDL con la creación de las tablas Dim\_Tiempo, Dim\_Ubicacion, etc.

```

Anthony\SQL... - Diagram_0*  script_04_dd...nthonny (83))
1  -- BLOQUE 5: MODELO DIMENSIONAL KIMBALL (DATA WAREHOUSE)
2  -- 1. Dimensión Tiempo
3  CREATE TABLE Dim_Tiempo (
4      TiempoKey INT IDENTITY(1,1) PRIMARY KEY,
5      Ano INT NOT NULL,
6      Semana INT NOT NULL,
7      Trimestre INT
8  );
9  GO
10
11 -- 2. Dimensión Ubicación
12 CREATE TABLE Dim_Ubicacion (
13     UbicacionKey INT IDENTITY(1,1) PRIMARY KEY,
14     Ubigeo VARCHAR(10) NOT NULL,
15     Departamento VARCHAR(100) NOT NULL,
16     Provincia VARCHAR(100),
17     Distrito VARCHAR(100) NOT NULL,
18     Localidad VARCHAR(150) NOT NULL
19 );
20 GO
21
22 -- 3. Dimensión Enfermedad
23 CREATE TABLE Dim_Enfermedad (
24     EnfermedadKey INT IDENTITY(1,1) PRIMARY KEY,
25     Enfermedad VARCHAR(100) NOT NULL
26 );
27 GO
28
29 -- 4. Dimensión Establecimiento (Cruzado con RENAES)
30 CREATE TABLE Dim_Establecimiento (
31     EstablecimientoKey INT IDENTITY(1,1) PRIMARY KEY,
32     Codigo_Renaes VARCHAR(20) NOT NULL,
33     Nombre_IPRESS VARCHAR(150) NOT NULL,
34     Red VARCHAR(100),
35     Microred VARCHAR(100)
36 );
37 GO

```

108 % No se encontraron problemas.

Mensajes


Los comandos se han completado correctamente.

Hora de finalización: 2026-10-06T15:52:25.6871556-05:00

108 % No se encontraron problemas.

Consulta ejecutada correctamente.

- Anexo N: Captura visual del diagrama del modelo relacional/estrella



- Anexo Ñ: Script del proceso de ETL para los Datasets.

The image shows a Visual Studio Code editor with a file explorer on the left and a code editor in the center. The file explorer shows a folder named 'ETL' containing files 'datos\_abiertos\_vigilancia\_zoonosis\_2000\_2...', 'etl\_pipeline1.py', and 'USLRC20260909215543\_xp.xls'. The code editor displays the 'etl\_pipeline1.py' script, which is a Python ETL process. The script includes imports for pandas, sqlalchemy, and urllib, followed by a connection to a SQL Server database. It then reads a CSV file, performs data cleaning (removing duplicates and standardizing characters), and finally inserts the data into a SQL Server database. The terminal at the bottom shows the execution of the script, displaying the progress of each step and the final completion message.

```

1  import pandas as pd
2  from sqlalchemy import create_engine
3  import urllib
4
5  print("=====")
6  print(" LOG DE EJECUCIÓN DEL SCRIPT PYTHON - PROCESO ETL")
7  print("=====")
8
9  # 1. Conexión de alto rendimiento a SQL Server (Localhost)
10 params = urllib.parse.quote_plus(
11     r"DRIVER={ODBC Driver 17 for SQL Server};"
12     r"SERVER=localhost\SQLEXPRESS;"
13     r"DATABASE=DataSalud_DB;"
14     r"Trusted_Connection=yes;"
15 )
16 engine = create_engine(f"mssql+pyodbc:///odbc_connect={params}", fast_executemany=True)
17
18 # 2. EXTRACCIÓN (Conteos de Entrada)
19 print("\n[Fase 1] Extracción de datos (Conteos de Entrada)")
20 archivo_csv = 'datos_abiertos_vigilancia_zoonosis_2000_2024.csv'
21 df_zoo = pd.read_csv(archivo_csv, encoding='latin-1', low_memory=False)
22
23 registros_entrada = len(df_zoo)
24 print(f"-> Registros leídos desde la fuente (MINSA): {registros_entrada}")
25
26 # 3. TRANSFORMACIÓN Y CALIDAD (Ingeniería de Datos Avanzada)
27 print("\n[Fase 2] Transformación, Normalización y Calidad de Datos")
28 df_clean = df_zoo.drop_duplicates().reset_index(drop=True)
29
30 # Mensaje EXACTO exigido por la rúbrica:
31 duplicados = registros_entrada - len(df_clean)
32 print(f"-> Duplicados descartados: {duplicados}")
33
34 print("-> Ejecutando saneamiento de caracteres y estandarización territorial...")
35 df_clean['distrito'] = df_clean['distrito'].fillna('DESCONOCIDO').astype(str).str.strip().str.upper()
36 df_clean['localidad'] = df_clean['localidad'].fillna(df_clean['distrito']).astype(str).str.strip().str.upper()
37 df_clean['diagnostic'] = df_clean['diagnostic'].fillna('NO ESPECIFICADO').astype(str).str.strip().str.upper()
38
39 if 'ubigeo' in df_clean.columns:

```

```

PS C:\CICLO 04 UPN\ETL> & c:\Users\Anthony\.local\bin\python3.14.exe "c:/CICLO 04 UPN/ETL/etl_pipeline1.py"
=====
LOG DE EJECUCIÓN DEL SCRIPT PYTHON - PROCESO ETL
=====

[Fase 1] Extracción de datos (Conteos de Entrada)
-> Registros leídos desde la fuente (MINSA): 128084


[Fase 2] Transformación, Normalización y Calidad de Datos
-> Duplicados descartados: 2388
-> Ejecutando saneamiento de caracteres y estandarización territorial...

[Fase 3] Carga al Data Warehouse (Conteos de Salida)
-> Conectando al motor relacional SQL Server...
-> 125696 registros insertados en Fact_VigilanciaZoonosis


=====
¡PROCESO ETL COMPLETADO CON ÉXITO!
=====

```

- **Anexo O: Esquema de Power BI, relaciones y conexiones**



- **Anexo P: Dashboard de Power BI, visualización de los 3 KPIs**



- *Anexo Q: Evidencia para el punto 1 - DataFrames*

```
[1]
✓ 8 s
from google.colab import drive
drive.mount('/content/drive')
```

Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force\_remount=True).

```
[2]
✓ 16 s
!pip install pyspark
from pyspark.sql import SparkSession
import time

# Iniciar la sesión de clúster local
spark = SparkSession.builder.appName("DataSalud_Zoonosis").getOrCreate()
print("¡Entorno Apache Spark inicializado con éxito!")
```

Requirement already satisfied: pyspark in /usr/local/lib/python3.13/dist-packages (4.0.4)  
Requirement already satisfied: py4j<0.10.9.10,>=0.10.9.7 in /usr/local/lib/python3.13/dist-packages (from pyspark) (0.10.9.9)  
¡Entorno Apache Spark inicializado con éxito!

```
[4]
✓ 7 s
# Cargar el dataset inmenso usando DataFrames distribuidos
df_spark = spark.read.csv("datos_abiertos_vigilancia_zoonosis_2000_2024.csv", header=True, inferSchema=True, encoding='iso-8859-1')

# Crear una vista temporal para usar sintaxis SQL pura sobre el clúster
df_spark.createOrReplaceTempView("vista_zoonosis")
print(f"Registros cargados en memoria distribuida: {df_spark.count()}")
```

Registros cargados en memoria distribuida: 128084

- *Anexo R: Script de SparkSQL prueba de Tiempo*

```
[5]
✓ 4 s
print("Iniciando procesamiento masivo multidimensional...")
start_time = time.time()

# Operación de agregación: Curva histórica por Año, Provincia y Enfermedad
resultado = spark.sql("""
    SELECT
        ano AS Anio_Epidemiologico,
        provincia AS Provincia,
        enfermedad AS Tipo_Zoonosis,
        COUNT(*) as Total_Casos
    FROM vista_zoonosis
    WHERE ano IS NOT NULL
        AND provincia IS NOT NULL
    GROUP BY ano, provincia, enfermedad
    ORDER BY Total_Casos DESC
""")

# Mostrar los top 10 resultados
resultado.show(10)

end_time = time.time()
print(f">>> Tiempo de ejecución en clúster PySpark: {round(end_time - start_time, 2)} segundos")
```

\*\*\* Iniciando procesamiento masivo multidimensional...  
+-----+-----+-----+-----+  
|Anio\_Epidemiologico|Provincia|Tipo\_Zoonosis|Total\_Casos|  
+-----+-----+-----+-----+  
|2024| MAYNAS| LEPTOSPIROSIS| 2689|  
|2019| MAYNAS| LEPTOSPIROSIS| 2310|  
|2020| MAYNAS| LEPTOSPIROSIS| 2237|  
|2023| MAYNAS| LEPTOSPIROSIS| 2066|  
|2019| TAMBOPATA| LEPTOSPIROSIS| 2002|  
|2015| TAMBOPATA| LEPTOSPIROSIS| 1447|  
|2012| MAYNAS| LEPTOSPIROSIS| 1150|  
|2013| MAYNAS| LEPTOSPIROSIS| 1132|  
|2014| MAYNAS| LEPTOSPIROSIS| 1128|  
|2022| MAYNAS| LEPTOSPIROSIS| 1113|  
+-----+-----+-----+-----+  
only showing top 10 rows  
>>> Tiempo de ejecución en clúster PySpark: 4.31 segundos

- Anexo S: Script de Prueba de Tiempo en SSMS

```
Prueba de Ti...nthony (81) X
1  -- Habilitar el cronómetro interno del motor SQL
2  SET STATISTICS TIME ON;
3
4  -- Ejecutar la operación analítica masiva
5  SELECT
6      ano AS Anio_Epidemiologico,
7      provincia AS Provincia,
8      enfermedad AS Tipo_Zoonosis,
9      COUNT(*) as Total_Casos
10 FROM Staging_Zoonosis
11 WHERE ano IS NOT NULL
12       AND provincia IS NOT NULL
13 GROUP BY ano, provincia, enfermedad
14 ORDER BY Total_Casos DESC;
15
16 -- Apagar el cronómetro
17 SET STATISTICS TIME OFF;
```

108 %    No se encontraron problemas.

Resultados    Mensajes

(4957 filas afectadas)

SQL Server Execution Times:  
CPU time = 3328 ms, elapsed time = 3631 ms.

Hora de finalización: 2026-10-06T22:25:12.6141698-05:00  
|

### Declaración de uso de Inteligencia Artificial

"Declaro que en la elaboración del presente desafío se utilizó inteligencia artificial de manera ética y bajo supervisión humana. La IA fue empleada únicamente para:

(colocar X en cada ítem que corresponda)

|                                                                                                                                                                                                                                                                                                          |      |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|
| Edición lingüística y de estilo (ej.: corrección gramatical, sugerencias de redacción).                                                                                                                                                                                                                  | (X ) |
| Traducción preliminar de textos.                                                                                                                                                                                                                                                                         | (X)  |
| Apoyo en la organización o síntesis de borradores del informe, la presentación o el guion de sustentación, basados en contenidos y evidencias de campo elaborados por la autora/el autor o el equipo.                                                                                                    | (X ) |
| Apoyo en el procesamiento o análisis de la información recopilada en la práctica de campo (ej.: tabulación de encuestas/entrevistas, generación de gráficos a partir de datos reales, verificación de cálculos o funciones). <b>Esto debe estar detallado en la parte del entregable correspondiente</b> | (X ) |
| Apoyo en la generación de diagramas, esquemas, mockups o piezas visuales como parte del desarrollo del entregable (especificando parámetros y verificando su fidelidad con la información recopilada). <b>Esto debe estar detallado en la parte del entregable correspondiente</b>                       | ( )  |
| No se usó Inteligencia Artificial                                                                                                                                                                                                                                                                        | ( )  |

La herramienta de IA utilizada fue: Gemini 3.8 Flash, Google (indicar nombre exacto, versión y proveedor).

Todo el contenido generado fue revisado, corregido y validado por la autora/el autor, asegurando precisión, integridad académica y fidelidad con los objetivos del trabajo."